

Lacuna Solar Survey Challenge: Counting Photovoltaic and Solar Panels from Aerial Imagery

Hugo Veríssimo

Complements of Machine Learning 24/25
University of Aveiro
Aveiro, Portugal
hugoverissimo@ua.pt

João Cardoso

Complements of Machine Learning 24/25
University of Aveiro
Aveiro, Portugal
joaopcardoso@ua.pt

Abstract—abstract

Keywords: EfficientNet, Object Detection

I. INTRODUCTION

Access to electricity and warm water is a basic necessity nowadays. In developing countries, the lack of a centralized distribution system makes this access harder for everyone. To improve on this gap, it is essential for governments, non-governmental organizations, and energy suppliers to understand how solar and solar thermal panels (for electricity and water heating, respectively) are distributed throughout the territory to ensure proper planning and effective policy making. In this context, a challenge was created by the Lacuna Fund and associate entities in the Zindi platform to develop a machine learning model capable of accurately detecting and counting the number of solar thermal (solar from here on) and photovoltaic panels in drone and satellite imagery.

In the present work, we have developed different approaches to the problem, where the two types of panels are considered in isolation: taking a regression type approach, where images are analysed as a whole and the target number of panels are provided per image; by identifying the panels through object detection and counting them afterwards; and by applying segmentation models to identify the regions of interest, analysing them and counting the panels.

II. STATE OF THE ART?

- A. *EfficientNetV2*
- B. *Object Detection*
- C. *Segmentation models*

asdasdas

III. METHODOLOGY

A. Data description (com EDA)

o dados, fornecidos pela propria competicao (citar), consistem em 4419 imagens, complementadas por metadata referente à origin da imagem e ao placement dos painéis, providing context on installation environments.

da totalidade destas imagens, 3312 (75%) contêm indicacoes das delimitacoes de conjutnos de painéis e de boilers, atraves de poligonos, assim como a quantidade que se encontra dentro de cada qual. as restantes 1107 (25%) nao têm esta informacao. Assim, por opcao da competicao, temos uma distribuicao de treino e teste de 75/25



Fig. 1: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

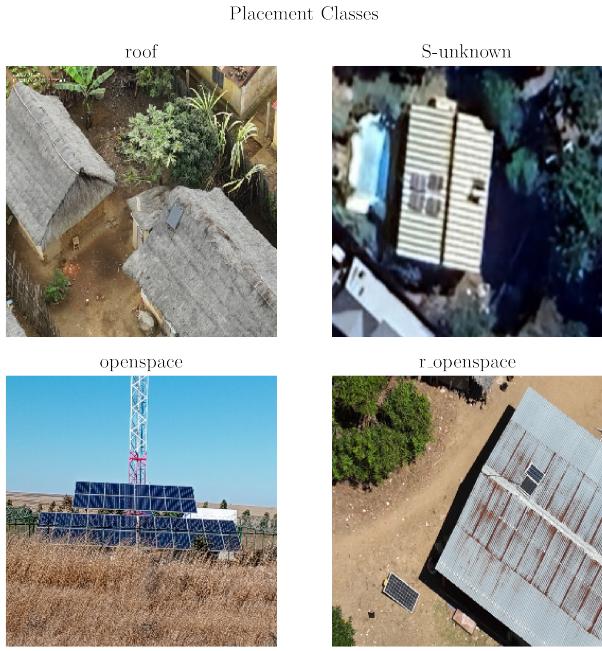


Fig. 2: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

nas figuras 1 e 2 podem-se observar as classes de origem e de placement relativas as imagens. as origins da imagem podem ser drone image (D) or satellite image (S), while the placement classes (Installations) sao distribuidas por on rooftops or terraces (roof), satellite images where the specific placement could not be determined (S-unknown), in open courtyards or gardens (openspace), that span both rooftops and outdoor spaces (r_openspace).

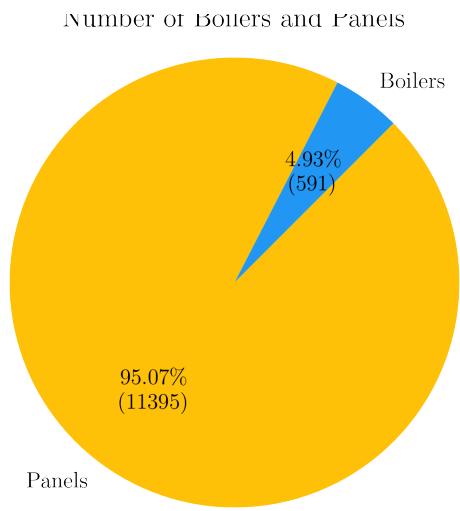


Fig. 3: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

ademas, é também importante referir uma presençā em maior peso de panels face ao numero de boilers, como se

verifica na figura 3

tendo em conta os poligonos referentes aos panels e boilers, também foi analisada a distribuicao da quantidade de painéis e de boilers naos poligonos que delimitam os conjuntos.

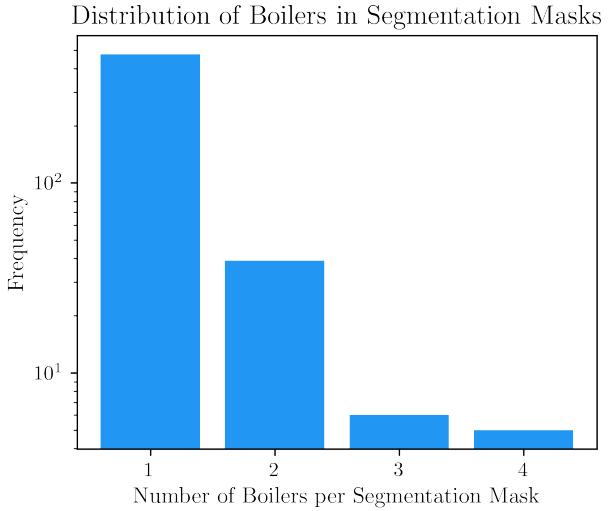


Fig. 4: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

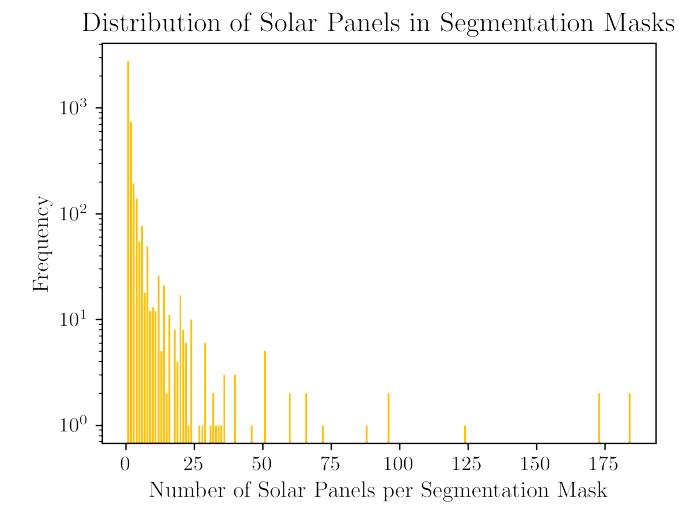


Fig. 5: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

as figuras 4 e 5 revelam esta distribuicao, revelando que (fiquei sem inspiracao)



Fig. 6: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

por fim, na imagem 6 pode-se verificar uma das imagens de treino e os respectivos poligonos referentes aos painéis e boilers convertidos numa mascara de segmentacao, onde se verifica a presenca de 4 grupos de solar panels, sendo cada um destes um grupo unitario, e 1 grupo de boilers, tambem unitario.

B. data: pre processamento e ques

atraves de algumas discussoes do forum da competicao, uma analise mais aprofundada de algumas imagens aleator e dos dados de treino, foram verificados alguns obstaculos para a aplicacao dos modelos.

nomeadamente, haviam linhas por poligono ao inves de linhas por imagem, as coordenadas dos poligonos eram strings ao inves de floats e algumas coordenadas tinham letras pelo meio.



Fig. 7: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

apos estas correcoes, uma das dificuldades tornou-se a validade dos poligonos. alguns poligonos tinham deslocacoes em relacao a posicao real dos paineis, outros tinham vertices misaligned, como se pode ver na imagem 7 alguns exemplos.

apesar de não ser um erro o excessive object inclusion, esta torna-se uma barreira a aplicacao direta de modelos como o yolo, que requerem uma mascara por objeto unitario.

de modo a combater a validade dos poligonos, foi efetuada uma revisao manual de cada qual, envolvendo a correcao de alguns poligonos deslocados e a eliminacao de imagens com poligonos misaligned.

com este processo foram perdidas apenas 263 imagens de treino.

por fim, foi criado um dataset de validacao a partir do de treino, tendo esta divisao sido feita numa proporcao de 80/20



Fig. 8: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

para alem disso, interessa tambem referir, que foi realizada data augmentation, nao como um processo de pre processamento, mas de forma online, no treino de todos os modelos, com as transformacoes HorizontalFlip VerticalFlip RandomRotate90 GaussianBlur CLAHE HueSaturationValue Normalize (dizer q fizemos normalizacao dos pixels) a imagem 8 mostra um exemplo de data augmentation.

C. Models implemented

....

aaa

IV. DJAISJD MODELS

llalal

A. zulo40 models type

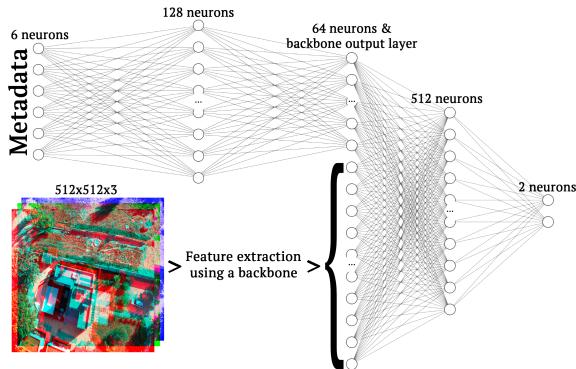


Fig. 9: CAPTION CAPTION CAPTION CAPTION CAPTION CAPTION

faz data augmentations
o cv q ele usa consiste em
- 3 folds
- para cada fold, um treino e um validacao (80/20), ajustanto
um modelo em cada fold.
- no fim, junta os modelos (3, pq sao 3 folds) e faz a media
das previsoes
- ou seja, usa 3 modelos como um só

ele usa Test-Time Augmentation (TTA), where the model makes multiple predictions on augmented versions of the same image (e.g., flipping, scaling, cropping). These predictions are later averaged to improve accuracy.

WE

- experimentamos diferentes backbones (desnetn, resnet, efnet)
- apes a verificacao de um melhor desempenho do efnet, decidiu-se fazer um fine tunning de hiperparametros como o lr, dropout, ...

B. yolo

ideia inicial era fazer segmentacao de conjuntos de painéis e de boilers e posteriormente com outro modelo fazer contagem
problema foi q o modelo ao reconhecer painéis individuais, mesmo em conjuntos identificava individuais, levando ao mau desempenho do modelo

surgiu a ideia de criar 4 classes: boiler, panel, conjunto de boilers, conjunto de panels, so q devido ao class imbalance o modelo teve resultados nao satisfatorios o suficiente

METER GRAFICO IMBALANCE

entao decidiu-se rever o dataset e separar manualmente os poligonos em painéis e boilers individuais, deixando de existir grupos de painéis

o yolo apresentou assim mt melhores resultados, apesar da reducao da dimensao do dataset em termos de imagens mas aumento de amostras do que realmente sao painéis e boilers individuais

fazer ja learning curve ou correr de novo last yolo?

IDEIA: correr de novo o last yolo, mas mudar hiperparametros (learning rate, adamw, etc.), a ver se temos uma solucao melhor

V. FAA02 IG

TABLE I: Error metrics for the train and test set (CF-LR), along with the number of samples for each.

Dataset	RMSE	MAE	Support
Train Set	0.58842	0.44604	80668
Test Set	1.24037	0.90651	20168

VI. DISCUSSION

<https://zindi.africa/competitions/lacuna-solar-survey-challenge/discussions/25674>

A. Performance Metrics

discussao

VII. CONCLUSION

conc

WORK LOAD

Both authors contributed equally to the project.

REFERENCES